Miloiu Cristi· U19 · Ce spune textul și nu spune satelitul: magnitudinea dezastrelor din rapoarte vs. Sentinel

Întrebarea mea

Pentru evenimentele de dezastru activate în Copernicus EMS în Europa (2017–2025): ce informație despre magnitudine poartă textul raportului și nu o poartă imaginea Sentinel bi-temporală, și invers, iar dezacordul dintre ele e anticipat de incertitudinea textului? (Q19.2 din catalog)

Unitatea și sursele

Unitatea: o activare EMS (un rând = un eveniment, static). 411 selectate (Europa, 2017–2025: incendii, inundații, furtuni), 391 în nucleul aliniat.

Text (EMS + GDACS) + Imagine (S1 principal, S2 secundar, din GEE) + Meteo (ERA5-Land, din GEE); magnitudine de referință: suprafața mapată de EMS + EM-DAT.

Cui îi folosește răspunsul

Unui analist de evaluare rapidă a pagubelor (EMS, IGSU): când se încrede în raport și când cere imagine.

Unde am ajuns

Etapa curentă: aliniere (CP1).

Făcut: pipeline-ul 01–06 rulează pentru toate sursele (EMS, GDACS, S1/S2, ERA5-Land, EM-DAT); tabelul aliniat și raportul de acoperire; matricea X cu scalare pe fold-uri LOYO; data card pe 6 surse; tabel SOA cu 10 articole.

Ce am schimbat față de plan: extracția GEE pe toate evenimentele, nu pe 20; ERA5 tot din GEE; suprafața mapată de EMS devine a treia vedere a magnitudinii; GDACS rămâne secundar (acoperă slab 2017–2020).

DOVADA ETAPEI

391 din 411 activări EMS (95%) se aliniază pe text + Sentinel-1 + ERA5; Sentinel-2 clar doar la 49%

Data card pe scurt (n = 411)

EMS: text 99% · AOI 98% · suprafață mapată 93%
Sentinel-1: 10 m, pre/post 97%
Sentinel-2: clar 49%; inundații doar 22/140
ERA5-Land: 0,1°, orar · 97%
GDACS: 33% (incendii abia din 2021)
EM-DAT: 33% (la nivel de țară)

Matricea X: 391 × 1.321

Imagine 14: ΔVV, ΔVH, dNDVI, dNBR, dMNDWI, fracții și arii schimbate, claritate S2
Meteo 4: precipitații eveniment / antecedente, Tmax, vânt maxim
Text ~1.303: TF-IDF 1–2-grame (BGE-M3 la CP2)
Scalare: log1p + z pe arii și ploi, z pe rest, L2 pe text; fit doar pe train

Cum se verifică

Repo: github.com/cristim67/medh, pipeline 01–06
Date: EMS API (20.10.2026), S1 GRD + S2 SR (GEE), ERA5-Land, EM-DAT (19.10.2026)
Split: LOYO, 9 fold-uri (2017–2025)
Ce înseamnă: analiza se poate face pe un nucleu de ~390 evenimente; S2 rămâne pe subset

SOA: articol	Surse	Metodă de explorare	Metrică → rezultat
CrisisMMD (ICWSM 2018)	tweet-uri text + imagine, 7 dezastre	adnotare crowdsourcing, 3 sarcini	imaginea poartă mai multă informație despre daune decât textul
Sen1Floods11 (CVPRW 2020)	Sentinel-1, etichete S2, 11 inundații	FCNN vs. prag Otsu pe VH	IoU inundație 0,339 vs. 0,285 (Otsu)
Deep CCA (ICML 2013)	două vederi: MNIST, XRMB	CCA neliniar vs. CCA liniar și KCCA	corelație canonică 39,7 vs. 28,0 (CCA, MNIST)
MMFlood (IEEE Access 2022)	Sentinel-1 + DEM; hărți EMS ca adevăr	segmentare multi-encoder SAR + DEM	mIoU 0,63 → peste 0,66
WorldFloods v2 (Sci. Rep. 2023)	Sentinel-2, Landsat; hărți EMS	U-Net nori/apă vs. prag MNDWI	impact Pakistan 2022: ~10 M oameni, 25.000 km²
CaBuAr (IEEE GRSM 2023)	Sentinel-2 pre/post, perimetre CAL FIRE	dNBR + Otsu vs. U-Net	F1 0,114 (dNBR) vs. 0,707 (U-Net)
BGE-M3 (Findings ACL 2024)	MIRACL (18 limbi), MKQA	embeddings dense / sparse / multi-vector	nDCG@10 71,5 vs. 31,9 (BM25)
Kuro Siwo (NeurIPS 2024)	serii S1, 43 inundații, adnotare experți	segmentare + change detection	F1 80,1%; un caz: CEMS vs. experți IoU 48%
MONITRS (NeurIPS 2025)	10.000+ evenimente, S2, text din știri	aliniere text–imagine, fine-tuning MLLM	clasificare 88,7% vs. ~50% (baseline)
3M (arXiv 2025)	tweet-uri EN/JA, S2; USGS MMI	MLLM: nivel de daune din text + imagine	r = 0,78 cu intensitatea măsurată

Detalii complete: CP1/datacard_U19.md (6 fișe) și CP1/soa_U19.md (referințe cu DOI). Acoperirea pe tip și an: reports/coverage.md.

Riscuri și planul până la CP2

Blocaje și riscuri

1. Nori: Sentinel-2 clar doar la 49% (inundații 22/140). S1 rămâne imaginea principală; S1 vs. S2 se compară doar pe subsetul cu ambele.

2. Referința de magnitudine e parțială: EM-DAT la 137/411 (lipsesc incendiile mici), populația EMS doar din 2023. Referința principală = suprafața mapată de EMS (382/411).

3. Data evenimentului: înainte de 2023 EMS dă doar data activării (până la ~9 zile după eveniment) → extrag data din text.

4. Leakage: suprafața EMS e derivată din imagini → e referință, nu intră în X.

Planul până la CP2 (săpt. 6)

Săptămâna 5: embeddings BGE-M3 pe text; data evenimentului din text; analiza uni/bivariată pe X (distribuții, corelații text–imagine–meteo).

Săptămâna 6: PCA pe fiecare fold LOYO (scree, loadings); alternativa declarată: CCA text ↔ imagine; protocolul și metricile de reprezentare.

La CP2 arăt: matricea X documentată, scree + loadings, metricile baseline-ului PCA pe LOYO.

Comparații pregătite: TF-IDF vs. BGE-M3; S1 vs. S2.

Secțiunea de articol: Methods (trăsături).